

Klasyfikacja gatunków irysów z wykorzystaniem naiwnego Bayesa

Martyna Skóra, Krzysztof Popiołek

2026-05-28

1. Wstęp

Zbiór danych Iris (znany również jako zbiór Andersona) został wprowadzony do literatury naukowej w 1936 roku przez brytyjskiego statystyka i biologa Ronalda Fishera. Materiał badawczy został zgromadzony przez amerykańskiego botanika Edgara Andersona, który na kanadyjskim półwyspie Gaspé zebrał i precyzyjnie zmierzył fizyczne parametry lokalnych populacji kosaćców. Wraz z rozwojem informatyki, ze względu na swoją zrównoważoną strukturę i brak uszkodzonych rekordów, baza ta stała się standardowym zbiorem referencyjnym, stając się jednym z najważniejszych i najczęściej badanych zbiorów testowych w historii statystyki oraz uczenia maszynowego.

Zbiór składa się ze 150 obserwacji, które podzielone są trzy równe klasy reprezentujące gatunki kosaćca: szczeniastego (*Iris setosa*), różnobarwnego (*Iris versicolor*) oraz wirginijskiego (*Iris virginica*). Dla każdego z kwiatów zebrano cztery precyzyjne pomiary ilościowe, określające w centymetrach długość i szerokość jego działek kielicha (sepal) oraz płatków korony (petal). Ta geometryczna struktura danych sprawiła, że identyfikacja gatunku przestała być wyłącznie zadaniem z dziedziny biologii, a stała się klasycznym problemem analitycznym, polegającym na wyznaczaniu matematycznych granic między pozornie podobnymi do siebie obiektami.

Celem tego sprawozdania jest przeprowadzenie procesu klasyfikacji gatunków irysów na podstawie ich cech wymiarowych, z wykorzystaniem algorytmu Naiwnego Klasyfikatora Bayesa. Dodatkowo, istotnym elementem badania jest ewaluacja oraz porównanie efektywności predykcyjnej modelu w zależności od zestawu wybranych cech objaśniających, co pozwoli na ocenę wpływu redukcji wymiarowości danych na jakość klasyfikacji.

2. Teoria

Plik `iris.data` składa się z informacji na temat 150 obserwacji kosaćców. Kolumny z danymi nie posiadały nagłówków, dlatego zostaną nadane w następnym etapie zgodnie z dokumentacją techniczną:

Sepal_length – długość działki kielicha (w cm),

Sepal_width – szerokość działki kielicha (w cm),

Petal_length – długość płatków korony (w cm),

Petal_width – szerokość płatków korony (w cm),

Class – gatunek irysa.

Test Shapiro-Wilka – służy do testowania podobieństwa rozkładu danej zmiennej do rozkładu normalnego. Hipoteza zerowa dla tego testu zakłada, że próba badawcza pochodzi z populacji o normalnym rozkładzie. Jeśli test Shapiro-Wilka osiąga istotność statystyczną ($p < 0,05$), świadczy to o rozkładzie odbiegającym od krzywej Gaussa.

Uczenie nadzorowane – paradygmat uczenia maszynowego, w którym algorytm trenowany jest na oznaczonym zbiorze danych, zawierającym parametry wejściowe oraz przypisane do nich z góry prawidłowe wyniki. Celem tego procesu jest wyekstrahowanie ukrytych reguł matematycznych, które pozwolą modelowi na samodzielne i trafne przewidywanie wartości dla nowych, nieznanych wcześniej przypadków.

Klasyfikacja – jedno z podstawowych zadań uczenia nadzorowanego, polegające na przyporządkowaniu nowego, nieznanego obiektu do jednej ze zdefiniowanych wcześniej, wzajemnie wykluczających się klas docelowych. Proces ten opiera się na analizie cech danego obiektu i porównaniu ich ze wzorcami wyekstrahowanymi z danych treningowych.

Twierdzenie Bayesa – opisuje prawdopodobieństwo zajścia danego zdarzenia na podstawie wcześniejszej wiedzy o warunkach, które mogą być związane ze zdarzeniem. Matematycznie wyraża się to wzorem:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)},$$

gdzie A i B są zdarzeniami oraz $P(B) > 0$, przy czym:

- $P(A)$ - prawdopodobieństwo wystąpienia zdarzenia A
- $P(B)$ - prawdopodobieństwo wystąpienia zdarzenia B
- $P(A|B)$ - prawdopodobieństwo wystąpienia zdarzenia A , pod warunkiem wystąpienia zdarzenia B ,
- $P(B|A)$ - prawdopodobieństwo wystąpienia zdarzenia B , pod warunkiem wystąpienia zdarzenia A

Zgodnie z dokumentacją pakietu ‘e1071’ udostępnioną w repozytorium CRAN, funkcja `naiveBayes` stanowi implementację standardowego naiwnego klasyfikatora bayesowskiego. Algorytm ten na podstawie dostarczonych zmiennych objaśniających (takich jak wymiary kwiatów) wylicza warunkowe prawdopodobieństwo przynależności danej obserwacji do określonej kategorii (w tym przypadku konkretnego gatunku irysa). W przypadku ciągłych danych liczbowych program z góry zakłada, że ich rozkład jest normalny (tzw. rozkład Gaussa). Podczas procesu nauki system estymuje odchylenie standardowe oraz średnią dla poszczególnych cech w ramach każdej ze zdefiniowanych klas. Mechanizm ten opiera się ponadto na kluczowym, silnym założeniu o warunkowej niezależności poszczególnych cech od siebie, stąd używane w nazwie słowo „naiwny”.

3. Preprocessing

W pierwszej kolejności wczytano plik z danymi z wykorzystaniem biblioteki ‘tidyverse’. Kolumnom nadano nazwy zgodnie z dokumentacją techniczną.

```
library(tidyverse)
irysy <- read_csv("iris.data",
                  col_names = c("Sepal_length",
                                "Sepal_width",
                                "Petal_length",
                                "Petal_width",
                                "Class"))
```

3.1 Ocena wstępna

Zapoznano się z tabelą wejściową. Nie zidentyfikowano żadnych wartości brakujących. Dla zmiennej ‘Class’ zdecydowano o usunięciu przedrostka “Iris-”, gdyż powtarza się dla wszystkich obserwacji oraz nie ma wpływu na rozpoznanie gatunku irysa.

3.2 Transformacja i przygotowanie danych

Na początek sprawdzono występowanie duplikatów w zbiorze wejściowym.

```
liczba_unikalnych <- irysy |> distinct() |> nrow()
cat("Liczba unikalnych obserwacji:", liczba_unikalnych, "\n")
```

Liczba unikalnych obserwacji: 147

W zbiorze zidentyfikowano powtarzające się wartości pomiarów (147 unikalnych obserwacji). Zdecydowano o nieusuwaniu tych rekordów, ponieważ w przypadku cech biologicznych mierzących populację naturalną, wystąpienie dwóch różnych osobników o identycznych parametrach geometrycznych jest zjawiskiem naturalnym i nie musi oznaczać błędu w bazie danych.

Wykonano podstawowe podsumowanie danych.

```
summary(irysy)
```

Sepal_length	Sepal_width	Petal_length	Petal_width
Min. :4.300	Min. :2.000	Min. :1.000	Min. :0.100
1st Qu.:5.100	1st Qu.:2.800	1st Qu.:1.600	1st Qu.:0.300
Median :5.800	Median :3.000	Median :4.350	Median :1.300
Mean :5.843	Mean :3.054	Mean :3.759	Mean :1.199
3rd Qu.:6.400	3rd Qu.:3.300	3rd Qu.:5.100	3rd Qu.:1.800
Max. :7.900	Max. :4.400	Max. :6.900	Max. :2.500

Class
Length:150
Class :character
Mode :character

Nie wykazano wartości brakujących. Ponadto rozstęp między wartościami minimalnymi a maksymalnymi dla poszczególnych cech numerycznych nie wykazał obecności drastycznych wartości odstających, które mogłyby negatywnie wpłynąć na proces klasyfikacji.

Dla kolumny 'Class' zidentyfikowano typ 'character', dlatego wykorzystano funkcję z biblioteki 'stringr' do usunięcia przedrostka "iris-" w nazwie gatunku irysa. Następnie przekonwertowano tę kolumnę z formatu tekstowego na czynnikowy (factor), ze względu na potrzeby algorytmu klasyfikującego.

```
irysy <- irysy |>
  mutate( Class = str_remove(Class, "Iris-"),
          Class = as.factor(Class))
```

Sprawdzono, że operacja została wykonana poprawnie. Oceniono, że tabela jest poprawna i zakończono preprocessing.

4. Modelowanie i klasyfikacja

4.1 Podział zbioru

Zdecydowano o podziale zbioru, w sposób: 80% obserwacji - zbiór treningowy, 20% - zbiór testowy. Podział wykonano w sposób losowy z ustawionym ziarnem, aby zapewnić jednakowe wykonanie kodu dla wszystkich użytkowników.

```
set.seed(100)
indeksy <- sample( 1:nrow(iris), 0.8*nrow(iris) )
zb_trening <- iris[indeksy, ]
zb_testowy <- iris[-indeksy, ]
knitr::kable(table(zb_trening$Class),
              caption = "Liczebność poszczególnych obserwacji w zbiorze treningowym.")
```

Table 1: Liczebność poszczególnych obserwacji w zbiorze treningowym.

Var1	Freq
setosa	39
versicolor	40
virginica	41

Zbiór treningowy zachował proporcje niemal idealnie równego podziału (39, 40 i 41 obserwacji dla poszczególnych klas). Z uwagi na równoliczność gatunków w pliku wejściowym, uzyskano zbalansowany rozkład w 30-elementowym zbiorze testowym (odpowiednio 11, 10 i 9 obserwacji). Taki wynik losowania uznano za optymalny, co pozwoliło wykluczyć ryzyko faworyzowania któregoś z gatunków na etapie ewaluacji.

4.2 Weryfikacja założeń modelu

Przeprowadzono testy normalności na zbiorze treningowym z wykorzystaniem testu Shapiro-Wilka, aby sprawdzić założenie modelu klasyfikującego o normalnym charakterze danych.

```
testy_normalnosci <- zb_trening |>
  pivot_longer(cols = c(Sepal_length, Sepal_width, Petal_length, Petal_width),
               names_to = "Cecha",
               values_to = "Wartosc") |>
  group_by(Class, Cecha) |>
  summarise(p_value = shapiro.test(Wartosc)$p.value, .groups = "drop") |>
  mutate(Normalny = ifelse(p_value > 0.05, "Tak", "Nie"))

knitr::kable(testy_normalnosci,
              digits = 4,
              caption = "Wyniki testu Shapiro-Wilka dla poszczególnych cech w rozbiciu na gatunki.")
```

Table 2: Wyniki testu Shapiro-Wilka dla poszczególnych cech w rozbiciu na gatunki.

Class	Cecha	p_value	Normalny
setosa	Petal_length	0.1586	Tak
setosa	Petal_width	0.0000	Nie
setosa	Sepal_length	0.3348	Tak
setosa	Sepal_width	0.2196	Tak
versicolor	Petal_length	0.2842	Tak
versicolor	Petal_width	0.0410	Nie
versicolor	Sepal_length	0.3468	Tak
versicolor	Sepal_width	0.3844	Tak
virginica	Petal_length	0.0300	Nie
virginica	Petal_width	0.1216	Tak
virginica	Sepal_length	0.2087	Tak
virginica	Sepal_width	0.2629	Tak

Analiza statystyczna testem Shapiro-Wilka wykazała, że w 9 na 12 zbadanych przypadków brak jest podstaw do odrzucenia hipotezy zerowej o normalności rozkładu (wartość $p > 0,05$). Nie ma więc podstaw do odrzucenia hipotezy o normalności dla tych zmiennych. Odstępstwa od rozkładu normalnego odnotowano dla długości płatk gatunku virginica ($p = 0,0300$), szerokości płatk gatunku versicolor ($p = 0,0410$) oraz szerokości płatk gatunku setosa ($p = 0,0000$). Wynik $p = 0,0000$ dla cechy Petal_width u gatunku setosa może wynikać ze specyfiki danych empirycznych, gdzie większość obserwacji przyjmuje stałą wartość 0,2 cm, co powoduje silne skupienie danych wokół średniej i brak zachowania symetrii rozkładu Gaussa. Pomimo niespełnienia założenia o normalności w tych trzech przypadkach, zdecydowano o kontynuowaniu analizy bez wprowadzania transformacji zmiennych. Decyzja ta podyktowana jest wysoką odpornością Naiwnego Klasyfikatora Bayesa na odstępstwa od teoretycznych założeń probabilistycznych, co zostanie zweryfikowane na etapie ewaluacji modelu na zbiorze testowym.

4.3 Klasyfikacja na podstawie wszystkich cech

Wykorzystano funkcję ‘naiveBayes’ z biblioteki ‘e1071’ do wykonania predykcji. Wykonano również tabelę obliczającą statystyki modelu.

```
library(e1071)
model1 <- naiveBayes(Class ~ .,
                      data = zb_trening)

przewidywanie1 <- predict(model1, zb_testowy)
wyniki1 <- table(zb_testowy$Class,
                 przewidywanie1)

knitr::kable(wyniki1,
              caption = "Macierz pomyłek (pełny wymiar cech). \\newline
                          Wiersze: stan faktyczny, Kolumny: predykcja modelu.")
```

Table 3: Macierz pomyłek (pełny wymiar cech).
Wiersze: stan faktyczny, Kolumny: predykcja modelu.

	setosa	versicolor	virginica
setosa	11	0	0
versicolor	0	9	1
virginica	0	1	8

```
poprawne1 <- diag(wyniki1)
wszystkie1 <- rowSums(wyniki1)
procenty1 <- round((poprawne1 / wszystkie1) * 100, 1)
calkowita1 <- round((sum(poprawne1) / sum(wszytskie1)) * 100, 1)
procenty1["całkowita"] <- calkowita1
knitr::kable(procenty1,
              caption = "Statystyki predykcji",
              col.names = "Skuteczność [%]")
```

Table 4: Statystyki predykcji

	Skuteczność [%]
setosa	100.0
versicolor	90.0
virginica	88.9
całkowita	93.3

4.4 Klasyfikacja na podstawie wybranych cech

4.4.1 Wybór cech

W celu wyboru cech, na podstawie których dokonana zostanie klasyfikacja, zdecydowano przygotować boxploty poszczególnych cech od gatunku, wykorzystując biblioteki 'ggplot2' oraz 'patchwork'. Przygotowano funkcję pomocniczą, mającą na celu ujednolicenie wykresów oraz ograniczenie długości kodu przez powtarzające się fragmenty.

```
library(patchwork)

draw_boxplot <- function(pdata, pcol, ptitle) {
  pdata |>
    ggplot(aes(x = Class, y = {{pcol}}, fill = Class)) +
    geom_boxplot() +
    labs(title = ptitle, x = "Gatunek", y = "Wymiar [cm]") +
    theme_minimal() +
    theme(legend.position = "none")
}


w1 <- draw_boxplot(zb_trening,
  Sepal_length,
  "Długość działki kielicha ('Sepal_length')")

w2 <- draw_boxplot(zb_trening,
  Sepal_width,
  "Szerokość działki kielicha (Sepal_width)")

w3 <- draw_boxplot(zb_trening,
  Petal_length,
  "Długość płatka korony (Petal_length)")

w4 <- draw_boxplot(zb_trening,
  Petal_width,
  "Szerokość płatka korony (Petal_width)")

(w1 + w2) / (w3 + w4)
```

Analiza wizualna rozkładu danych na wykresach ramkowych (box-plotach) pokazała, że poszczególne parametry pomiarowe wykazują zróżnicowaną użyteczność w procesie grupowania kwiatów. Największą separowalnością okazał się gatunek *Iris setosa* – jego wymiary wyraźnie odstają od pozostałych we wszystkich badanych kategoriach. Najtrudniejsze okazało się zróżnicowanie ze sobą gatunków *Iris versicolor* oraz *Iris virginica*. Przeprowadzone pomiary dla ich działek kielicha dawały rezultaty bardzo do siebie podobne, przez co obszary zmienności na wykresach znacząco się na siebie nakładały. Ponadto dane z wymiarów kielicha charakteryzowały się zauważalną podatnością na tzw. wartości odstające (pojawiające się skrajnie wysokie lub niskie pomiary z obu stron rozkładu), co w przypadku algorytmów klasyfikujących buduje wysokie ryzyko błędnego przypisywania kategorii. Zdecydowano więc, że w dalszej części badania zostaną użyte tylko dwie zmienne – długość (*Petal_length*) i szerokość (*Petal_width*) płatków. Mimo że rozróżnienie między dwoma podobnymi gatunkami nadal stanowiło pewne wyzwanie, to te parametry pozwalały na najlepsze podzielenie danych.

4.4.2 Klasyfikacja

Do przeprowadzenia klasyfikacji ponownie wykorzystano funkcję ‘naiveBayes’. Również przygotowano tabelę obliczającą skuteczność modelu.

```
model2 <- naiveBayes(Class ~ Petal_length + Petal_width,
                      data = zb_trening)

przewidywanie2 <- predict(model2, zb_testowy)
wyniki2 <- table(zb_testowy$Class,
                 przewidywanie2)

knitr::kable(wyniki2,
              caption = "Macierz pomyłek (cechy Petal_length i Petal_width). \\newline
                        Wiersze: stan faktyczny, Kolumny: predykcja modelu.")
```

Table 5: Macierz pomyłek (cechy Petal_length i Petal_width).
Wiersze: stan faktyczny, Kolumny: predykcja modelu.

	setosa	versicolor	virginica
setosa	11	0	0
versicolor	0	9	1
virginica	0	1	8

```
poprawne2 <- diag(wyniki2)
wszystkie2 <- rowSums(wyniki2)
procenty2 <- round((poprawne2 / wszystkie2) * 100, 1)
calkowita2 <- round((sum(poprawne2) / sum(wszytskie2)) * 100, 1)
procenty2["calkowita"] <- calkowita2
knitr::kable(procenty2,
              caption = "Statystyki predykcji",
              col.names = "Skuteczność [%]")
```

Table 6: Statystyki predykcji

	Skuteczność [%]
setosa	100.0
versicolor	90.0
virginica	88.9
całkowita	93.3

Zmniejszenie liczby cech o połowę (z czterech do zaledwie dwóch wymiarów płatków) nie wpłynęło negatywnie na wyniki. Całkowita skuteczność przewidywań pozostała bez zmian i wyniosła 93,3%. Wynik ten potwierdza wnioski wyciągnięte wcześniej z analizy wykresów. Zmienne określające długość i szerokość działki kielicha (Sepal_length i Sepal_width) w analizowanym eksperymencie nie poprawiły skuteczności klasyfikacji.

5. Podsumowanie

Celem ćwiczenia było przeprowadzenie klasyfikacji trzech gatunków irysów (*Iris setosa*, *Iris versicolor* oraz *Iris virginica*) na podstawie popularnego zbioru danych Andersona. Wykorzystany algorytm Naiwnego Klasyfikatora Bayesa miał za zadanie nauczyć się rozpoznawać gatunek kwiatu, opierając się wyłącznie na podanych wymiarach jego budowy.

Dostępna bazę 150 obserwacji podzielono losowo na dwie części: zbiór treningowy - 80% danych, na którym model się uczył, oraz zbiór testowy - 20%, który posłużył do oceny jego skuteczności. W ramach analizy przetestowano dwa warianty klasyfikacji.

W pierwszym podejściu uwzględniono wszystkie cztery parametry (wymiary płatków i działek kielicha). Algorytm osiągnął bardzo dobrą skuteczność całkowitą na poziomie 93,3%. Najlepiej poradził sobie z gatunkiem *Iris setosa*, bezbłędnie przypisując wszystkie obserwacje. Jedyne błędy wynikały z trudności w rozróżnieniu fizycznie podobnych do siebie gatunków *versicolor* i *virginica*.

Kluczowym etapem projektu okazał się jednak dobór odpowiednich cech. Wstępna analiza wykresów pokazała, że rozmiary działek kielicha mocno się na siebie nakładają, co ograniczyło ich przydatność w procesie dyskryminacji klas. Analiza wizualna wykresów pudełkowych pozwoliła zauważyć, że cechy te charakteryzują się niską zmiennością dla gatunków *versicolor* oraz *virginica*, co nie zwiększyło jego zdolności predykcyjnych. Z tego powodu wygenerowano drugi wariant modelu, w którym zostawiono wyłącznie dwie zmienne: długość i szerokość płatków korony. Pomimo ograniczenia danych o połowę, uproszczony model powtórzył wynik pierwszego, utrzymując skuteczność predykcji na poziomie 93,3%.

Wyniki sugerują, że odpowiedni dobór cech może być równie istotny jak liczba dostępnych zmiennych. Odrzucenie zmiennych, które nie wnoszą istotnych i jednoznacznych informacji (w tym przypadku wymiarów działek kielicha), w przeprowadzonym eksperymencie nie wpłynęło na jakość wyników, a ponadto ograniczyło wykorzystanie zasobów obliczeniowych komputera.

6. Bibliografia

<https://CRAN.R-project.org/package=e1071>

<https://cran.r-project.org/web/packages/e1071/e1071.pdf>

<https://dplyr.tidyverse.org/>

<https://ggplot2.tidyverse.org/reference/>

<https://rstudio.github.io/cheatsheets/data-visualization.pdf>

<https://pogotowiestatystyczne.pl/slowniki/test-shapiro-wilka/>

<https://zpe.gov.pl/a/wprowadzenie/DT5Eatxae>

https://www.naukowiec.org/wiedza/statystyka/test-shapiro-wilka_758.html

7. Kod

```
knitr::opts_chunk$set(echo = TRUE, comment="", warning=FALSE, message=FALSE)
library(tidyverse)
irysy <- read_csv("iris.data",
                  col_names = c("Sepal_length",
                                "Sepal_width",
                                "Petal_length",
                                "Petal_width",
                                "Class"))

liczba_unikalnych <- irysy |> distinct() |> nrow()
cat("Liczba unikalnych obserwacji:", liczba_unikalnych, "\n")
summary(irysy)
irysy <- irysy |>
  mutate( Class = str_remove(Class, "Iris-"),
          Class = as.factor(Class))
set.seed(100)
indeksy <- sample( 1:nrow(irysy), 0.8*nrow(irysy) )
zb_trening <- irysy[indeksy, ]
zb_testowy <- irysy[-indeksy, ]
knitr::kable(table(zb_trening$Class),
              caption = "Liczebność poszczególnych obserwacji w zbiorze treningowym.")
testy_normalnosci <- zb_trening |>
  pivot_longer(cols = c(Sepal_length, Sepal_width, Petal_length, Petal_width),
               names_to = "Cecha",
               values_to = "Wartosc") |>
  group_by(Class, Cecha) |>
  summarise(p_value = shapiro.test(Wartosc)$p.value, .groups = "drop") |>
  mutate(Normalny = ifelse(p_value > 0.05, "Tak", "Nie"))

knitr::kable(testy_normalnosci,
              digits = 4,
              caption = "Wyniki testu Shapiro-Wilka dla poszczególnych cech w rozbiciu na gatunki.")
library(e1071)
model1 <- naiveBayes(Class ~ .,
                     data = zb_trening)

przewidywanie1 <- predict(model1, zb_testowy)
wyniki1 <- table(zb_testowy$Class,
                 przewidywanie1)

knitr::kable(wyniki1,
              caption = "Macierz pomyłek (pełny wymiar cech). \\newline
                          Wiersze: stan faktyczny, Kolumny: predykcja modelu.")

poprawne1 <- diag(wyniki1)
wszystkie1 <- rowSums(wyniki1)
procenty1 <- round((poprawne1 / wszystkie1) * 100, 1)
calkowita1 <- round((sum(poprawne1) / sum(wszytskie1)) * 100, 1)
procenty1["całkowita"] <- calkowita1
knitr::kable(procenty1,
              caption = "Statystyki predykcji",
              col.names = "Skuteczność [%]")
```

```

library(patchwork)

draw_boxplot <- function(pdata, pcol, ptitle) {
  pdata |>
    ggplot(aes(x = Class, y = {{pcol}}, fill = Class)) +
    geom_boxplot() +
    labs(title = ptitle, x = "Gatunek", y = "Wymiar [cm]") +
    theme_minimal() +
    theme(legend.position = "none")
}

w1 <- draw_boxplot(zb_trening,
  Sepal_length,
  "Długość działki kielicha ('Sepal_length')")

w2 <- draw_boxplot(zb_trening,
  Sepal_width,
  "Szerokość działki kielicha (Sepal_width)")

w3 <- draw_boxplot(zb_trening,
  Petal_length,
  "Długość płatka korony (Petal_length)")

w4 <- draw_boxplot(zb_trening,
  Petal_width,
  "Szerokość płatka korony (Petal_width)")

(w1 + w2) / (w3 + w4)
model2 <- naiveBayes(Class ~ Petal_length + Petal_width,
  data = zb_trening)

przewidywanie2 <- predict(model2, zb_testowy)
wyniki2 <- table(zb_testowy$Class,
  przewidywanie2)

knitr::kable(wyniki2,
  caption = "Macierz pomyłek (cechy Petal_length i Petal_width). \\newline
  Wiersze: stan faktyczny, Kolumny: predykacja modelu.")

poprawne2 <- diag(wyniki2)
wszystkie2 <- rowSums(wyniki2)
procenty2 <- round((poprawne2 / wszystkie2) * 100, 1)
calkowita2 <- round((sum(poprawne2) / sum(wszystkie2)) * 100, 1)
procenty2["całkowita"] <- calkowita2
knitr::kable(procenty2,
  caption = "Statystyki predykcji",
  col.names = "Skuteczność [%]")

```