

Analiza danych z pliku titanic_new

Mateusz Ożóg, Krzysztof Popiołek

2026-05-16

1. Wstęp

RMS Titanic był brytyjskim transatlantyckim statkiem pasażerskim typu Olympic, zbudowanym w stoczni Harland and Wolff w Belfaście. W momencie wodowania w 1912 roku stanowił największy i najbardziej zaawansowany technicznie statek parowy na świecie. Jego dziewiczy rejs rozpoczął się 10 kwietnia 1912 roku, a planowana trasa wiodła z Southampton do Nowego Jorku. Na pokładzie znajdowało się łącznie ponad 2200 osób, w tym załoga oraz pasażerowie podzieleni na trzy odrębne klasy. W pierwszej klasie podróżowali wpływowi politycy, przemysłowcy i arystokraci, podczas gdy klasę trzecią zajmowali w dużej mierze ubodzy emigranci z Europy, szukający pracy w Stanach Zjednoczonych. W nocy z 14 na 15 kwietnia 1912 roku, podczas przeprawy przez północny Atlantyk, jednostka zderzyła się z górą lodową. Kolizja uszkodziła kadłub z prawej burty na tyle rozlegle, że woda zalała sześć przedziałów wodoszczelnych, przekraczając dopuszczalne limity bezpieczeństwa konstrukcji. W rezultacie liniowiec zatonął w ciągu niespełna trzech godzin. W katastrofie zginęło ponad 1500 pasażerów i członków załogi, co czyni ją jedną z najbardziej badanych tragedii morskich w historii.

Katastrofa Titanica, choć była nagłym i chaotycznym wydarzeniem, została zdominowana przez normy społeczne epoki edwardiańskiej. Podczas akcji ratunkowej oficerowie egzekwowali nieoficjalny protokół nakazujący pierwszeństwo kobietom oraz dzieciom przy obsadzaniu szalup ratunkowych. Ta kulturowo uwarunkowana kolejność ewakuacji sprawiła, że szanse na przetrwanie nie były rozłożone losowo, lecz zależały wprost od cech demograficznych pasażerów. Z tego powodu wiek oraz płeć stały się kluczowymi czynnikami determinującymi ocalenie.

Celem tego sprawozdania jest analiza wpływu cech demograficznych i statusu majątkowego na przeżywalność pasażerów rejsu RMS Titanic.

2. Teoria

Plik `titanic_new.csv` składa się z informacji na temat 891 pasażerów, znajdujących się na pokładzie RMS Titanic. W skład danych wchodzi:

- 'Passenger.id' - ID pasażera,
- 'Survived' - informacja, czy pasażer przeżył (1 - tak, 0 - nie),
- 'Pclass' - klasa podróży (1, 2 lub 3),
- 'Name' - tytuł, imię i nazwisko pasażera,
- 'Sex' - płeć,
- 'Age' - wiek,
- 'SibSp' - liczba partnerów/rodzeństwa danego pasażera na pokładzie,
- 'Parch' - liczba rodziców/dzieci danego pasażera na pokładzie,
- 'Ticket' - numer biletu,
- 'Fare' - koszt podróży (w funtach brytyjskich),
- 'Cabin' - kabina,
- 'Embarked' - port, na którym wsiadł pasażer (S - Southampton, C - Cherbourg, Q - Queenstown).

W tym sprawozdaniu skupiono się na analizie zmiennych: 'Survived', 'Pclass', 'Sex', 'Age'. Wybrano te zmienne, ponieważ uznano za warte sprawdzenia, czy stwierdzenie "najpierw kobiety i dzieci" ma swoje przełożenie w danych historycznych. Ponadto chciano sprawdzić znaczenie dodatkowego parametru, klasy, a zatem statusu majątkowego na szanse na przeżycie.

Imputacja - technika stosowana w analizie danych do uzupełniania brakujących wartości. Braki danych mogą wynikać z różnych powodów, takich jak błędy pomiarowe, problemy z rejestrowaniem danych czy opuszczenia przez respondenta. Imputacja pozwala na zachowanie integralności zestawu danych, co jest kluczowe dla dokładności i wiarygodności analizy statystycznej.

Wartości skrajne - to pojedyncze obserwacje, które drastycznie odbiegają od pozostałych danych w próbie statystycznej (są od nich znacznie większe lub mniejsze) lub są niemożliwe do osiągnięcia.

Średnia (arytmetyczna) - klasyczna miara położenia, tendencji centralnej, będąca ilorazem sumy zaobserwowanych wartości zmiennej mierzonej przez liczbę obserwacji.

Mediana (lub drugi kwartył) - środkowy punkt zbioru danych uporządkowanego rosnąco lub malejąco. Jest to wartość, która dzieli zestaw danych na dwie równe części.

Częstość względna - stosunek liczby wystąpień danego wariantu badanej cechy do całkowitej liczby obserwacji w badanej próbie statystycznej. W sprawozdaniu wykorzystywana do wyznaczania procentowego wskaźnika przeżywalności.

Analiza wielowymiarowa - zbiór metod statystycznych polegających na jednoczesnym badaniu rozkładu co najmniej dwóch zmiennych w celu identyfikacji ukrytych zależności, interakcji oraz wpływu poszczególnych cech na zmienną objaśnianą.

Test normalności rozkładu - procedura wnioskowania statystycznego weryfikująca hipotezę zerową, która zakłada, że badana próba badawcza pochodzi z populacji o rozkładzie normalnym. Narzędzie niezbędne do wyboru odpowiedniej miary korelacji.

Współczynnik korelacji liniowej Pearsona - parametryczna miara określająca poziom i kierunek zależności liniowej między dwiema zmiennymi ilościowymi. Podstawowym warunkiem do jej prawidłowego zastosowania

we wnioskowaniu statystycznym jest założenie, że badane cechy charakteryzują się rozkładem zbliżonym do normalnego oraz nie posiadają skrajnych wartości odstających, które mogłyby zaburzyć wynik estymacji.

Współczynnik korelacji rangi Spearmana – nieparametryczna miara siły i kierunku zależności monotonicznej między dwiema zmiennymi. W przeciwieństwie do korelacji Pearsona nie wymaga założenia o normalności rozkładu i operuje na rangach przypisanych wartościom, a nie na ich rzeczywistych miarach.

3. Preprocessing

W pierwszej kolejności wczytano plik z danymi z wykorzystaniem biblioteki “tidyverse”.

```
library(tidyverse)
titanic <- read.csv("titanic_new.csv", header = T)
```

3.1 Selekcja wstępna

Zapoznano się z tabelą wejściową. Zdecydowano o nieuwzględnieniu w dalszych etapach analizy zmiennych ‘Passenger.id’ oraz ‘Ticket’. Obie kolumny zawierają numery porządkowe, dlatego nie ma możliwości ich wykorzystania w procesie badawczym. Zmienną ‘Cabin’ odrzucono ze względu na krytyczną liczbę braków danych, uniemożliwiającą rzetelną analizę. Kolumny ‘Fare’, ‘Embarked’, ‘SibSp’ oraz ‘Parch’ wykluczono z dalszego przetwarzania, ponieważ wykraczają one poza główny cel badawczy, skupiony wyłącznie na podstawowej demografii i statusie społecznym. Z kolei zmienną ‘Name’ pozostawiono w zbiorze tymczasowo, wyłącznie w celu późniejszej ekstrakcji tytułów grzecznościowych, które posłużą do imputacji braków w zmiennej określającej wiek pasażerów.

3.2 Oczyszczanie danych i identyfikacja wartości brakujących

Wykorzystano funkcje `summary()` oraz `count()` w celu oceny poprawności danych oraz zidentyfikowania braków.

```
titanic |> select(Survived, Pclass, Sex, Age) |> summary()
```

Survived		Pclass		Sex		Age	
Min.	: -1.0000	Min.	:1.000	Length:	891	Min.	: 0.42
1st Qu.:	0.0000	1st Qu.:	2.000	Class	:character	1st Qu.:	20.12
Median	: 0.0000	Median	:3.000	Mode	:character	Median	:28.00
Mean	: 0.7542	Mean	:2.309			Mean	:29.70
3rd Qu.:	1.0000	3rd Qu.:	3.000			3rd Qu.:	38.00
Max.	:112.0000	Max.	:3.000			Max.	:80.00
						NA's	:177

```
titanic |> count(Survived, sort = TRUE)
```

Survived	n
0	549
1	338
112	2
-1	1
111	1

```
titanic |> count(Pclass)
```

Pclass	n
1	216
2	184
3	491

```
titanic |> count(Sex)
```

Sex	n
f2emale	1
feemale	3
female	310
mal3e	1
mal4e	1
male	573
malle	1
malwe	1

```
titanic |> count(Age) |> head(10)
```

Age	n
0.42	1
0.67	1
0.75	2
0.83	2
0.92	1
1.00	7
2.00	10
3.00	6
4.00	10
5.00	4

Sprawdzono poprawność danych w tabeli wejściowej. Zidentyfikowano następujące błędy w kolumnach będących przedmiotem analizy:

- W kolumnie ‘Survived’ występują cztery wartości spoza zbioru wartości prawidłowych. Ponieważ nie ma możliwości zidentyfikować na podstawie dostępnych danych, czy dany pasażer przeżył, a kolumna ‘Survived’ jest kluczowa dla poprawnego przeprowadzenia analizy, zdecydowano o usunięciu wierszy z niepoprawnymi danymi po procesie imputacji, aby na jej czas dysponować maksymalną liczbą obserwacji,
- Dla zmiennej ‘Sex’ zaobserwowano błędy w pisowni odpowiedzi. Jest jednak możliwe na ich podstawie zidentyfikować poprawną płeć pasażera.

```
titanic$Sex[titanic$Sex %in% c("feemale", "f2emale")] <- "female"
titanic$Sex[titanic$Sex %in% c("mal3e", "mal4e", "malle", "malwe")] <- "male"
```

Podczas korekty literówek w zmiennej ‘Sex’ zastosowano metodę jawnego mapowania zidentyfikowanych błędów. Gwarantuje to pełną kontrolę nad transformacją danych – program modyfikuje wyłącznie te wartości, które zostały uprzednio zweryfikowane, co chroni analizę przed przypadkowym zniekształceniem wyników.

- w kolumnie ‘Age’ zidentyfikowano 177 wartości brakujących. Zostaną one zimputowane w następnym etapie.

Dla zmiennej ‘Pclass’ nie zidentyfikowano żadnych błędów.

Ponieważ nie można zweryfikować poprawności imion i nazwisk pasażerów, zdecydowano stworzyć zmienną pomocniczą ‘Title’ z kolumny ‘Name’, składającą się z tytułów pasażerów.

```
tit1 <- titanic |> mutate(
  Title = str_replace(Name, "\.+", "", ""),
  Title = str_replace(Title, "\\..+", "")
)
tit1 |> count(Title, sort = TRUE)
```

Title	n
Mr	517
Miss	182
Mrs	125
Master	40
Dr	7
Rev	6
Col	2
Major	2
Mlle	2
Capt	1
Don	1
Jonkheer	1
Lady	1
Mme	1
Ms	1
Sir	1
the Countess	1

Ustalono, że nowopowstała kolumna ‘Title’ nie zawiera widocznych błędów oraz braków. Zdecydowano o wykorzystaniu jej w miejscu kolumny ‘Name’ w dalszych krokach.

3.3 Imputacja danych

Analiza zbioru wykazała liczne brakujące dane w kolumnie ‘Age’. Z uwagi na kluczowe znaczenie tej zmiennej oraz znaczną liczbę braków, zrezygnowano z usuwania wierszy na rzecz imputacji.

Ze względu na występowanie pasażerów o tytułach, dla których policzenie mediany mogłoby być niemożliwe zdecydowano podzielić ten proces na dwa etapy. Dla osób, których tytuł występuje więcej niż raz zastąpiono wartości brakujące medianą wieku wyliczoną w obrębie danej klasy podróży oraz wyodrębnionego tytułu pasażera. Dla pasażerów, których tytuł występuje tylko raz w danej klasie, postanowiono o uzupełnieniu danych medianą klasy, do której należą. Wybór ten podyktowany był faktem, że status społeczny i majątkowy na statku silnie korelował z wiekiem. Zastosowanie mediany zminimalizowało z kolei ryzyko zaburzenia szacunków przez wartości skrajne.

```
# więcej niż jeden
tit1 <- tit1 |>
  group_by(Title, Pclass) |>
```

```
mutate(Age = ifelse(is.na(Age) & n() > 1, median(Age, na.rm = TRUE), Age)) |>
ungroup()

# dokładnie jeden
tit1 <- tit1 |>
  group_by(Pclass) |>
  mutate(Age = ifelse(is.na(Age), median(Age, na.rm = TRUE), Age)) |>
  ungroup()

tit1 |> select(Age) |> summary()
```

```
      Age
Min.   : 0.42
1st Qu.:21.00
Median :26.00
Mean   :29.15
3rd Qu.:36.75
Max.   :80.00
```

Wygenerowano podsumowanie statystyczne zmiennej ‘Age’. Potwierdziło ono skuteczność zastosowanego algorytmu imputacji. W strukturze danych nie zidentyfikowano żadnych wartości brakujących, a rozkład wieku pasażerów zachował spójność logiczną.

Zakończono proces uzupełniania danych, dlatego usunięto obserwacje, dla których nie można ustalić, czy pasażer przeżył.

```
tit1 <- tit1 |> filter(Survived %in% c(0, 1))
tit1 |> count(Survived)
```

Survived	n
0	549
1	338

Potwierdzono, że pozostałe dane spełniają kryteria początkowe.

Stwierdzono, że znaczna liczba wartości w zmiennej ‘Age’ uniemożliwiłaby przeprowadzenie analizy w sposób czytelny. Podzielono wartości na grupy.

```
tit1 <- tit1 |> mutate(AgeGroup = cut(Age,
  breaks = c(0, 12, 18, 50, 100),
  labels = c("Children", "Youth", "Adults", "Seniors")))
```

Przedziały wiekowe zostały zdefiniowane jako prawostronnie domknięte (zgodnie z domyślnym działaniem algorytmu kategoryzującego), co eliminuje niejednoznaczności przy przypisywaniu pasażerów o wieku niecałkowitym. Stworzono następujące grupy:

- ‘Children’ - pasażerowie w wieku 0-12 lat,
- ‘Youth’ - pasażerowie w wieku 12-18 lat,
- ‘Adults’ - pasażerowie w wieku 18-50 lat,

- ‘Seniors’ - pasażerowie w wieku 50+ lat.

Zredukowano wymiarowość danych, ograniczając je do zmiennych: ‘Survived’, ‘Pclass’, ‘Sex’, ‘AgeGroup’.

```
library(dplyr)
tit_sel <- select(tit1, "Survived", "Pclass", "Sex", "AgeGroup")
tit_sel |> head(10)
```

Survived	Pclass	Sex	AgeGroup
0	3	male	Adults
1	1	female	Adults
1	3	female	Adults
1	1	female	Adults
0	3	male	Adults
0	3	male	Adults
0	1	male	Seniors
0	3	male	Children
1	3	female	Adults
1	2	female	Youth


Stwierdzono, że otrzymana tabela spełnia wszystkie założenia początkowe i nie zawiera jawnych błędów.

4. Analiza - statystyki opisowe

Właściwą analizę statystyczną rozpoczęto od zbadania ogólnego poziomu przeżywalności pasażerów w wyselekcjonowanym zbiorze danych. Wyznaczenie głównego punktu odniesienia było niezbędne do późniejszej oceny, w jakim stopniu poszczególne cechy demograficzne i majątkowe determinowały szanse na ocalenie względem średniej dla całej populacji na statku.

```
mean_ogolem <- tit_sel |>
  summarise(sur = sum(Survived == 1) / n())

tit_sel |>
  ggplot(aes(x = "Ogółem", fill = as.factor(Survived))) +
  geom_bar(position = "fill") +
  scale_fill_manual(values = c("red", "green"),
                    name = "Status",
                    labels = c("Nie przeżył", "Przeżył")) +
  geom_text(data = mean_ogolem,
            aes(x = "Ogółem", y = 0.1, label = round(sur * 100)),
            inherit.aes = FALSE,
            size = 4) +
  labs(title = "Wykres ogólnej przeżywalności",
       x = "",
       y = "Przeżywalność [%]")
```



```
tabela_ogolna <- tit_sel |>
  summarise(
    Wszystkich = n(),
    Przezylo = sum(Survived == 1),
    Zginelo = sum(Survived == 0)
  )

knitr::kable(tabela_ogolna,
  caption = "Ogólna liczba pasażerów")
```

Table 8: Ogólna liczba pasażerów

Wszystkich	Przeżyło	Zginelo
887	338	549

Zestawienie wykazało, że katastrofę przeżyło 338 z 887 uwzględnionych osób, co przełożyło się na ogólny wskaźnik przeżywalności na poziomie 38%. Śmierć poniosło 549 pasażerów, co stanowiło 62% badanej populacji. Uzyskany wynik ogólny (38%) przyjęto jako bazową miarę referencyjną do weryfikacji wpływu kolejnych zmiennych w dalszych etapach badań.

Na potrzeby dalszej analizy stworzono dwie funkcje pomocnicze. Mają one na celu ujednolicenie wyglądu wykresów i tabel oraz ograniczenie długości kodu przez powtarzające się fragmenty.

```
draw_plot <- function(pdata, px, ptitle, pxtitle, pmean, psur)
{
  pdata |>
    ggplot(aes(x = {{px}}, fill = as.factor(Survived))) +
    geom_bar(position = "fill") +
    scale_fill_manual(values = c("red", "green"),
                      name = "Status",
                      labels = c("Nie przeżył", "Przeżył")) +
    geom_text(data = pmean,
              aes(x = {{px}},
                  label = round({{psur}}*100)),
              y = 0.1,
              inherit.aes = FALSE,
              size = 4) +
    labs(title = ptitle, x = pxtitle, y = "Przeżywalność [%]") +
    scale_y_continuous(labels = function(x) x * 100)
}

draw_table <- function(pdata, pcaption, ...)
{
  tabela <- pdata |>
    group_by(...) |>
    summarise(
      Wszystkich = n(),
      Przezylo = sum(Survived == 1),
      Zginelo = sum(Survived == 0),
      .groups = 'drop'
    )
  knitr::kable(tabela,
               caption = pcaption)
}
```

Funkcja `draw_plot()` służy do tworzenia wykresów przeżywalności od innej zmiennej/innych zmiennych. Ponadto na każdym słupku wyświetlana jest procentowa wartość przeżywalności zaokrąglona do całości. Funkcja przyjmuje parametry:

- 'pdata' - tabela danych,
- 'px' - zmienna względem której tworzony jest wykres,
- 'ptitle' - tytuł wykresu,
- 'pxtitle' - tytuł osi X.


Funkcja `draw_table()` tworzy tabele zawierającą wartości ilościowe, dotyczące przeżywalności od innej zmiennej/innych zmiennych. Przyjmuje parametry:

- 'pdata' - tabela danych
- pcaption - tytuł tabeli
- ... (zmienne grupujące) – jedna lub więcej zmiennych, według których dane zostaną pogrupowane i zliczone

Wygenerowano zestawienie dystrybucji ocalałych z uwzględnieniem podziału na cztery predefiniowane grupy wiekowe. Miało to na celu sprawdzenie, jaki wpływ na przeżywalność miała przynależność do różnych grup wiekowych.

```
mean <- tit_sel |>
  group_by(AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  AgeGroup,
  "Wykres przeżywalności od wieku",
  "Wiek",
  mean, sur)
```



```
draw_table(tit_sel,
  "Liczba pasażerów w grupach wiekowych",
  AgeGroup)
```

Table 9: Liczba pasażerów w grupach wiekowych

AgeGroup	Wszystkich	Przeżyło	Zginęło
Children	72	41	31
Youth	103	49	54
Adults	648	226	422


AgeGroup	Wszystkich	Przeżyło	Zginęło
Seniors	64	22	42

Analiza struktury wieku wykazała, że katastrofę przeżyło jedynie 41 z 72 dzieci oraz 49 ze 103 młodzieży, podczas gdy wskaźnik przeżywalności dla dorosłych i seniorów osiągnął odpowiednio 35% i 34%. Wynik ten potwierdził priorytetowe traktowanie najmłodszych, jednak stosunkowo wysoki odsetek ofiar wśród dzieci wzbudził przypuszczenia o wpływie dodatkowych czynników na proces ratunkowy.

Ponieważ wiek okazał się być niedeterministyczny czynnikiem, zdecydowano zbadać rozkład płci pasażerów, aby sprawdzić jej wpływ na przeżywalność.

```
mean <- tit_sel |>
  group_by(Sex) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  Sex,
  "Wykres przeżywalności od płci",
  "płeć",
  mean,
  sur)
```



```
draw_table(tit_sel,
  "Liczba pasażerów według płci",
  Sex)
```

Table 10: Liczba pasażerów według płci


Sex	Wszystkich	Przeżyło	Zginęło
female	312	231	81
male	575	107	468

Spośród kobiet na pokładzie znaczna większość (74%) przeżyła katastrofę. Inaczej ma się sytuacja u mężczyzn, gdzie zmarło 468 spośród 575. Potwierdziło to przypuszczenia o kluczowym wpływie płci na przeżywalność wśród pasażerów na pokładzie. Mimo tak silnej dominacji reguły pierwszeństwa, odnotowano śmierć aż 26% populacji kobiet, przy jednoczesnym ocaleniu niemal jednej piątej populacji mężczyzn (19%). Ta zauważalna anomalia statystyczna wskazała, że sama zmienna płci nie determinowała ratunku.

Biorąc pod uwagę fakt, że ani wiek, ani płeć nie determinowały ocalenia w sposób ostateczny, w kolejnym kroku poddano analizie status majątkowy. Zweryfikowano, czy klasa wykupionego biletu stanowiła dodatkowe, nieoficjalne kryterium podczas ewakuacji.

```
mean <- tit_sel |>
  group_by(Pclass) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  Pclass,
  "Wykres przeżywalności od klasy",
  "klasa",
  mean,
  sur)
```



```
draw_table(tit_sel,
  "Liczba pasażerów według klasy",
  Pclass)
```

Table 11: Liczba pasażerów według klasy

Pclass	Wszystkich	Przeżyło	Zginęło
1	214	134	80
2	184	87	97


Pclass	Wszystkich	Przeżyło	Zginęło
3	489	117	372

Pasażerowie podróżujący w pierwszej klasie osiągnęli przeżywalność na poziomie 63%, co stanowiło niemal trzykrotnie wyższy odsetek niż w przypadku klasy trzeciej (24%). W drugiej klasie rejs ocalało 87 spośród 184 osób (47%). Odnotowano wyraźną zależność, według której wyższy status majątkowy bezpośrednio zwiększał szansę na przeżycie katastrofy.

Każda ze zmiennych jednowymiarowych wykazała silny, lecz nie absolutny wpływ na przeżywalność, niezbędne stało się zbadanie ich wzajemnych interakcji. W pierwszej kolejności zestawiono wiek pasażerów ze statusem majątkowym, aby zweryfikować, czy fundamentalna zasada ratowania najmłodszych obowiązywała w równej mierze na wszystkich pokładach statku.

```
mean <- tit_sel |>
  group_by(Pclass, AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  AgeGroup,
  "Wykres przeżywalności od klasy i wieku",
  "klasa, wiek",
  mean,
  sur) +
  facet_wrap(~Pclass)
```



```
draw_table(tit_sel,
  "Liczba pasażerów według klasy i wieku",
  Pclass, AgeGroup)
```

Table 12: Liczba pasażerów według klasy i wieku


Pclass	AgeGroup	Wszystkich	Przeżyło	Zginęło
1	Children	4	3	1
1	Youth	12	11	1
1	Adults	159	102	57
1	Seniors	39	18	21
2	Children	17	17	0
2	Youth	12	6	6
2	Adults	140	61	79
2	Seniors	15	3	12
3	Children	51	21	30
3	Youth	79	32	47
3	Adults	349	63	286
3	Seniors	10	1	9

Analiza dwuwymiarowa ujawniła drastyczne nierówności w realizacji protokołu ewakuacyjnego. O ile dzieci podróżujące w drugiej klasie zostały ocalone w 100% (17 na 17 osób), o tyle w najniższej, trzeciej klasie uratowano zaledwie 41% najmłodszych pasażerów (21 z 51 osób). Analogiczną zależność odnotowano w grupie młodzieży – reprezentanci pierwszej klasy osiągnęli wskaźnik przetrwania rzędu 92% (11 z 12 osób), podczas gdy ich rówieśnicy z trzeciej klasy ocaleli w zaledwie 41% przypadków (32 z 79 osób). Rozkład ten dostarczył twardych przesłanek na to, że status majątkowy znacząco zaburzał regułę pierwszeństwa ze względu na wiek.

W celu pogłębionej weryfikacji słuszności reguły „kobiety i dzieci najpierw”, w kolejnym kroku skrzyżowano zmienne płci oraz wieku. Pozwoliło to ocenić, czy priorytet ewakuacyjny dla najmłodszych obowiązywał w równym stopniu chłopców i dziewczynki, oraz jak zachowywały się wskaźniki przeżywalności dla poszczególnych płci na różnych etapach życia.

```
mean <- tit_sel |>
  group_by(Sex, AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  AgeGroup,
  "Wykres przeżywalności od płci i wieku",
  "płeć, wiek",
  mean,
  sur) +
  facet_wrap(~Sex)
```



```
draw_table(tit_sel,
  "Liczba pasażerów według płci i wieku",
  Sex, AgeGroup)
```

Table 13: Liczba pasażerów według płci i wieku


Sex	AgeGroup	Wszystkich	Przeżyło	Zginęło
female	Children	31	18	13
female	Youth	69	46	23
female	Adults	195	151	44
female	Seniors	17	16	1
male	Children	41	23	18
male	Youth	34	3	31
male	Adults	453	75	378
male	Seniors	47	6	41

Przeprowadzona analiza ujawniła zjawisko całkowicie odwrotne do początkowych założeń protokołu ratunkowego. W grupie kobiet odnotowano wyraźny trend wzrostowy przeżywalności wraz z wiekiem – katastrofę przetrwało aż 94% pasażerek z grupy seniorów (16 z 17 osób) oraz 77% dorosłych kobiet (151 ze 195 osób), podczas gdy wskaźnik ten dla najmłodszych dziewczynek (grupa dzieci) wyniósł zaledwie 58% (18 z 31 osób). Z kolei w populacji mężczyzn zachowano klasyczną, przewidywaną hierarchię ewakuacyjną: najwyższą przeżywalność osiągnęli chłopcy (56%, tj. 23 z 41 osób), natomiast w starszych grupach wiekowych odsetek ocalałych drastycznie spadał, oscylując w granicach 9-17% (uratowano zaledwie 3 z 34 mężczyzn w grupie młodzieży oraz 75 z 453 dorosłych mężczyzn). Rozkład ten dostarczył sygnałów na to, że wiek dziecięcy stanowił realną przepustkę do ocalenia wyłącznie w przypadku płci męskiej, natomiast w przypadku kobiet priorytetowo traktowano osoby dorosłe i starsze.

W celu wyjaśnienia anomalii zidentyfikowanej w poprzednim zestawieniu – zaskakująco niskiego wskaźnika przeżywalności najmłodszych pasażerek w stosunku do dorosłych kobiet – zestawiono zmienną płci z klasą podróży. Krok ten miał na celu zweryfikowanie, czy to obiektywny status majątkowy nie stanowił ukrytego czynnika zakłócającego oficjalne priorytety ratunkowe.

```
mean <- tit_sel |>
  group_by(Sex, Pclass) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  Sex,
  "Wykres przeżywalności od płci i klasy",
  "płeć, klasa",
  mean,
  sur) +
  facet_wrap(~Pclass)
```



```
draw_table(tit_sel,
  "Liczba pasażerów według płci i klasy",
  Sex, Pclass)
```

Table 14: Liczba pasażerów według płci i klasy

Sex	Pclass	Wszystkich	Przeżyło	Zginęło
female	1	94	91	3
female	2	76	70	6
female	3	142	70	72
male	1	120	43	77
male	2	108	17	91
male	3	347	47	300


Zestawienie to rzuciło nowe światło na mechanikę ewakuacji, stając w wyraźnej kontrze do uproszczonych wniosków z poprzednich analiz. Odnotowano niemal stuprocentową skuteczność ratowania kobiet z klas wyższych – ocalało 97 pasażerek z pierwszej oraz 92 z drugiej klasy. Z kolei w klasie trzeciej wskaźnik ten drastycznie załamał się, a ratunek znalazło jedynie 49 kobiet. Taki rozkład danych ostatecznie wyjaśnił zaniżony wynik przeżywalności dla najmłodszych dziewczynek zaobserwowany w poprzednim przekroju. Wynikał on bezpośrednio z faktu, iż znaczna część populacji dziecięcej podróżowała w trzeciej klasie, gdzie ich priorytet ewakuacyjny okazał się ewidentnie niższy niż priorytet dorosłych kobiet z pierwszej i drugiej klasy. Stanowi to poważną przesłankę na to, że obiektywny status majątkowy weryfikował i nierzadko łamał regułę pierwszeństwa dla kobiet i dzieci.

Ostatnim etapem analizy statystyk opisowych było stworzenie trójwymiarowego zestawienia, uwzględniającego jednocześnie płeć, klasę podróży oraz wiek. Krok ten miał na celu ostateczną weryfikację hierarchii ewakuacyjnej poprzez wyłonienie podzbiorów o skrajnie najwyższych i najniższych szansach na przeżycie.

```
mean <- tit_sel |>
  group_by(Sex, Pclass, AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  Pclass,
  "Wykres przeżywalności i klasy od wieku i płci",
  "wiek, klasa",
  mean,
  sur) +
facet_grid(Sex ~ AgeGroup) +
labs(y = "Przeżywalność [%], płeć")
```

Wykres przeżywalności i klasy od wieku i płci



```
draw_table(tit_sel,
            "Liczba pasażerów według płci, klasy i wieku",
            Sex, Pclass, AgeGroup)
```

Table 15: Liczba pasażerów według płci, klasy i wieku

Sex	Pclass	AgeGroup	Wszystkich	Przeżyło	Zginęło
female	1	Children	1	0	1
female	1	Youth	10	10	0
female	1	Adults	70	68	2
female	1	Seniors	13	13	0
female	2	Children	8	8	0

Sex	Pclass	AgeGroup	Wszystkich	Przeżyło	Zginęło
female	2	Youth	6	6	0
female	2	Adults	59	54	5
female	2	Seniors	3	2	1
female	3	Children	22	10	12
female	3	Youth	53	30	23
female	3	Adults	66	29	37
female	3	Seniors	1	1	0
male	1	Children	3	3	0
male	1	Youth	2	1	1
male	1	Adults	89	34	55
male	1	Seniors	26	5	21
male	2	Children	9	9	0
male	2	Youth	6	0	6
male	2	Adults	81	7	74
male	2	Seniors	12	1	11
male	3	Children	29	11	18
male	3	Youth	26	2	24
male	3	Adults	283	34	249
male	3	Seniors	9	0	9

Zestawienie trójwymiarowe dostarczyło kompleksowego obrazu mechaniki ratunkowej, obnażając sztywną, wielopoziomową hierarchię. Analiza najliczniejszych podzbiorów wykazała niemal stuprocentową skuteczność ratunku w grupie dorosłych kobiet z klas wyższych. Katastrofę przetrwało aż 97% pasażerek z pierwszej klasy (ocalono 68 z 70 osób) oraz 92% dorosłych kobiet z klasy drugiej (54 z 59 osób). W wyraźnym kontraście do tych wyników uplasowały się statystyki dla najliczniejszej demograficznie grupy na statku, czyli dorosłych mężczyzn z trzeciej klasy. Przeżywalność w tym segmencie wyniosła zaledwie 12%, co oznacza, że z 283 osób uratowano tylko 34. Co istotne, najniższy wskaźnik ocalenia (9%) odnotowano wśród dorosłych mężczyzn z klasy drugiej, gdzie katastrofę przetrwało zaledwie 7 z 81 pasażerów.

Tak drastyczny rozkład zasygnalizował, że nieoficjalny protokół „kobiety i dzieci najpierw” w praktyce funkcjonował z potężnym, ukrytym filtrem majątkowym. Bezwzględny priorytet ewakuacyjny posiadały dojrzałe kobiety z wyższych pokładów, podczas gdy mężczyzn – z wyłączeniem pierwszej klasy – systematycznie spisywano na straty. Jednocześnie z analitycznego punktu widzenia zachodziła konieczność odrzucenia najmniej licznych podzbiorów. W przypadku grup takich jak dzieci z pierwszej klasy (obejmujących zaledwie od 1 do 3 obserwacji) czy seniorów z drugiej i trzeciej klasy, zrezygnowano z wyciągania wiążących wniosków. Zbyt mała próba badawcza w tych segmentach nie pozwoliła na rzetelne stwierdzenie istotności statystycznej i stwarzała ryzyko błędnej interpretacji wyników.

5. Podsumowanie

W wyniku przeprowadzonej eksploracji i czyszczenia danych (w tym procesu imputacji braków w zmiennej wieku oraz usunięcia obserwacji z błędnym statusem przetrwania) uzyskano ostateczny zbiór badawczy liczący 887 pasażerów. Ogólny wskaźnik przeżywalności w tej grupie wyniósł niespełna 38%, co stanowiło punkt odniesienia do dalszych, szczegółowych porównań.

Zestawienie statystyk wskazało, że najsilniejszą zmienną warunkującą ocalenie z katastrofy okazała się płeć. Kobiety przeżyły w 74% przypadków, co stanowiło niemal czterokrotnie wyższy odsetek w porównaniu do mężczyzn, spośród których uratowało się zaledwie 19%. Ta drastyczna dysproporcja potwierdziła ścisłą realizację wytycznych ewakuacyjnych faworyzujących kobiety.

Drugim kluczowym czynnikiem była klasa podróży, będąca bezpośrednim odzwierciedleniem statusu majątkowego pasażerów. Zaobserwowano wyraźny trend spadkowy przeżywalności wraz z obniżeniem się standardu biletu. Pasażerowie pierwszej klasy ocalili w 63%, drugiej w 47%, natomiast z najliczniejszej, trzeciej klasy uratowało się jedynie 24% osób.

Kategoryzacja wieku na cztery przedziały (Dzieci, Młodzież, Dorośli, Seniorzy) pozwoliła dostrzec kolejne istotne prawidłowości. Ogólne ujęcie wykazało, że wiek faworyzował najmłodszych – wskaźnik ocalenia w grupie dzieci wyniósł 57% i malał proporcjonalnie do dorastania. Jednakże pogłębiona analiza krzyżowa ujawniła, że tendencja ta dotyczyła niemal wyłącznie mężczyzn. W przypadku kobiet odnotowano zjawisko całkowicie odwrotne – szanse na przeżycie rosły wraz z wiekiem, osiągając 94% u seniorek, podczas gdy dla najmłodszych dziewczynek wynosiły zaledwie 58%.

Analiza wielowymiarowa pokazała, że poszczególne cechy silnie na siebie oddziaływały, tworząc rygorystyczną hierarchię przetrwania. Przynależność do priorytetowej grupy wiekowej lub płciowej nie gwarantowała sukcesu, jeśli pasażer podróżował w najniższej klasie. Doskonałym tego przykładem byli najmłodsi pasażerowie: uratowało się 100% dzieci z drugiej klasy oraz 75% z pierwszej, ale już tylko 41% dzieci z klasy trzeciej.

Podsumowując, zgromadzone przesłanki statystyczne wykazały, że nieoficjalny protokół „kobiety i dzieci najpierw” nie był respektowany w sposób bezwzględny. Proces ewakuacji został drastycznie zniekształcony przez filtr majątkowy. Najwyższe szanse na ratunek (powyżej 90%) miały dojrzałe kobiety podróżujące pierwszą i drugą klasą. Z kolei największą śmiertelnością charakteryzowała się grupa dorosłych mężczyzn z najniższych pokładów, co pokazuje, że przynależność do trzeciej klasy drastycznie redukowałą szanse na ocalenie, nierzadko łamiąc zasady pierwszeństwa przysługujące dzieciom.

Jaką analizę można wykonać na tych danych? Które dane będą nam do tego potrzebne?

- Analiza predykcyjna z wykorzystaniem uczenia maszynowego Rozszerzeniem przeprowadzonych badań mogłoby być zbudowanie modelu, który na podstawie cech pasażera przewidywałby jego szanse na przeżycie katastrofy. Wykorzystując algorytmy takie jak regresja logistyczna czy drzewa decyzyjne, można by sprawdzić, na ile trafnie da się zautomatyzować typowanie ocalałych. Do wytrenowania takiego modelu niezbędne byłoby użycie zmiennej docelowej Survived oraz głównych cech demograficznych, czyli Sex, Pclass i Age.
- Analiza wpływu portu zaokrętowania na szanse przetrwania Kolejnym naturalnym krokiem badawczym byłoby sprawdzenie, czy miejsce wejścia na pokład miało pośredni wpływ na przeżywalność. Biorąc pod uwagę, że pasażerowie z różnych miast (Southampton, Cherbourg, Queenstown) mogli reprezentować odmienne przekroje społeczne i majątkowe, celowym byłoby zbadanie zależności między portem zaokrętowania a przydziałem do konkretnej klasy podróży. Wymagałoby to przywrócenia do zbioru analitycznego odrzuconej na etapie wstępnej selekcji kolumny Embarked i zestawienia jej ze zmiennymi Survived oraz Pclass.

- Analiza wpływu wielkości rodziny na ewakuację Ciekawym kierunkiem badawczym byłoby sprawdzenie, czy pasażerowie podróżujący samotnie mieli ułatwioną drogę ucieczki w porównaniu do dużych rodzin, które mogły tracić cenny czas na szukanie się pod pokładami. W tym celu należałoby wrócić do odrzuconych na etapie preprocessingu kolumn SibSp (liczba rodzeństwa/małżonków) oraz Parch (liczba rodziców/dzieci). Na ich podstawie można by wygenerować zupełnie nową zmienną określającą wielkość rodziny i zestawić ją ze statusem przetrwania.
- Analiza korelacji i rozkładu opłat za bilet Kolejną niewykorzystaną dotąd ścieżką jest szczegółowa analiza kosztów podróży, ukrytych w zmiennej ciągłej Fare. Pozwoliłoby to zbadać, czy sama cena biletu wprost przekładała się na przetrwanie oraz jak silnie wartość ta korelowała z wiekiem czy nadaną klasą. Do przeprowadzenia takich obliczeń, na przykład za pomocą testu normalności rozkładu i wynikowo korelacji Pearsona/Spearmana, potrzebne byłoby ponowne włączenie zmiennej Fare do zbioru badawczego.

6. Bibliografia

https://pl.wikipedia.org/wiki/RMS_Titanic

<https://campus.lakeforest.edu/frank/FILES/MLFfiles/Bio150/Titanic/TitanicMETA.pdf>

<https://www.britannica.com/topic/Titanic/Maiden-voyage>

<https://stat.gov.pl/metainformacje/slownik-pojec/pojecia-stosowane-w-statystyce-publicznej/2937,pojecie.html>

<https://dplyr.tidyverse.org/>

<https://astrafox.pl/slownik/imputacja/>

https://stringr.tidyverse.org/reference/str_replace.html?q=str_replace#null

<https://ggplot2.tidyverse.org/reference/>

<https://rstudio.github.io/cheatsheets/data-visualization.pdf>

7. Kod

```
knitr::opts_chunk$set(echo = FALSE, comment="")
library(tidyverse)
titanic <- read.csv("titanic_new.csv", header = T)
titanic |> select(Survived, Pclass, Sex, Age) |> summary()
titanic |> count(Survived, sort = TRUE)
titanic |> count(Pclass)
titanic |> count(Sex)
titanic |> count(Age) |> head(10)
titanic$Sex[titanic$Sex %in% c("feemale", "f2emale")] <- "female"
titanic$Sex[titanic$Sex %in% c("mal3e", "mal4e", "malle", "malwe")] <- "male"
tit1 <- titanic |> mutate(
  Title = str_replace(Name, "\\.+", ""),
  Title = str_replace(Title, "\\..+", "")
)
tit1 |> count(Title, sort = TRUE)
# więcej niż jeden
tit1 <- tit1 |>
  group_by(Title, Pclass) |>
  mutate(Age = ifelse(is.na(Age) & n() > 1, median(Age, na.rm = TRUE), Age)) |>
  ungroup()

# dokładnie jeden
tit1 <- tit1 |>
  group_by(Pclass) |>
  mutate(Age = ifelse(is.na(Age), median(Age, na.rm = TRUE), Age)) |>
  ungroup()

tit1 |> select(Age) |> summary()
tit1 <- tit1 |> filter(Survived %in% c(0, 1))
tit1 |> count(Survived)
tit1 <- tit1 |> mutate(AgeGroup = cut(Age,
  breaks = c(0, 12, 18, 50, 100),
  labels = c("Children", "Youth", "Adults", "Seniors")))

library(dplyr)
tit_sel <- select(tit1, "Survived", "Pclass", "Sex", "AgeGroup")
tit_sel |> head(10)
mean_ogolem <- tit_sel |>
  summarise(sur = sum(Survived == 1) / n())

tit_sel |>
  ggplot(aes(x = "Ogółem", fill = as.factor(Survived))) +
  geom_bar(position = "fill") +
  scale_fill_manual(values = c("red", "green"),
    name = "Status",
    labels = c("Nie przeżył", "Przeżył")) +
  geom_text(data = mean_ogolem,
    aes(x = "Ogółem", y = 0.1, label = round(sur * 100)),
    inherit.aes = FALSE,
    size = 4) +
  labs(title = "Wykres ogólnej przeżywalności",
    x = "",
```

```

y = "Przeżywalność [%]"

tabela_ogolna <- tit_sel |>
  summarise(
    Wszystkich = n(),
    Przezylo = sum(Survived == 1),
    Zginelo = sum(Survived == 0)
  )

knitr::kable(tabela_ogolna,
  caption = "Ogólna liczba pasażerów")
draw_plot <- function(pdata, px, ptitle, pxtitle, pmean, psur)
{
  pdata |>
    ggplot(aes(x = {{px}}, fill = as.factor(Survived))) +
    geom_bar(position = "fill") +
    scale_fill_manual(values = c("red", "green"),
                      name = "Status",
                      labels = c("Nie przeżył", "Przeżył")) +
    geom_text(data = pmean,
              aes(x = {{px}},
                  label = round({{psur}}*100)),
              y = 0.1,
              inherit.aes = FALSE,
              size = 4) +
    labs(title = ptitle, x = pxtitle, y = "Przeżywalność [%]") +
    scale_y_continuous(labels = function(x) x * 100)
}

draw_table <- function(pdata, pcaption, ...)
{
  tabela <- pdata |>
    group_by(...) |>
    summarise(
      Wszystkich = n(),
      Przezylo = sum(Survived == 1),
      Zginelo = sum(Survived == 0),
      .groups = 'drop'
    )
  knitr::kable(tabela,
    caption = pcaption)
}

mean <- tit_sel |>
  group_by(AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
  AgeGroup,
  "Wykres przeżywalności od wieku",
  "Wiek",
  mean, sur)

```

```

draw_table(tit_sel,
            "Liczba pasażerów w grupach wiekowych",
            AgeGroup)
mean <- tit_sel |>
  group_by(Sex) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
           Sex,
           "Wykres przeżywalności od płci",
           "płeć",
           mean,
           sur)

draw_table(tit_sel,
            "Liczba pasażerów według płci",
            Sex)
mean <- tit_sel |>
  group_by(Pclass) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
           Pclass,
           "Wykres przeżywalności od klasy",
           "klasa",
           mean,
           sur)

draw_table(tit_sel,
            "Liczba pasażerów według klasy",
            Pclass)
mean <- tit_sel |>
  group_by(Pclass, AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
           AgeGroup,
           "Wykres przeżywalności od klasy i wieku",
           "klasa, wiek",
           mean,
           sur) +
  facet_wrap(~Pclass)

draw_table(tit_sel,
            "Liczba pasażerów według klasy i wieku",
            Pclass, AgeGroup)

mean <- tit_sel |>
  group_by(Sex, AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
           AgeGroup,

```

```

    "Wykres przeżywalności od płci i wieku",
    "płeć, wiek",
    mean,
    sur) +
facet_wrap(~Sex)

draw_table(tit_sel,
    "Liczba pasażerów według płci i wieku",
    Sex, AgeGroup)
mean <- tit_sel |>
  group_by(Sex, Pclass) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
    Sex,
    "Wykres przeżywalności od płci i klasy",
    "płeć, klasa",
    mean,
    sur) +
facet_wrap(~Pclass)

draw_table(tit_sel,
    "Liczba pasażerów według płci i klasy",
    Sex, Pclass)
mean <- tit_sel |>
  group_by(Sex, Pclass, AgeGroup) |>
  summarise(sur = sum(Survived == 1) / n())

draw_plot(tit_sel,
    Pclass,
    "Wykres przeżywalności i klasy od wieku i płci",
    "wiek, klasa",
    mean,
    sur) +
facet_grid(Sex ~ AgeGroup) +
labs(y = "Przeżywalność [%]", płeć")

draw_table(tit_sel,
    "Liczba pasażerów według płci, klasy i wieku",
    Sex, Pclass, AgeGroup)

```